秦海岩 Haiyan Qin



Agent 基础设施与推理系统

北京航空航天大学博士研究生 · ApxInf 核心开发者

haiyanq@buaa.edu.cn

qhy991.github.io | GitHub | Google Scholar

研发 Agent 运行时、工作流编排与 GPU 评测基础设施，构建可验证、可恢复的自动优化流程，连接智能体与推理引擎。

教育与实习经历

北京航空航天大学 · 集成电路工程博士在读 2023.09 - 2028.07 预计

北京航空航天大学 · 微电子科学与工程本科 2019 - 2023

无问芯穹 Infinigence AI · 实习生 2025.09 - 至今

代表成果

- 曾助力 Infinigence AI 获得 NVIDIA SOL-ExecBench 双榜第一。
- 参与 GLM-5.3 推理优化，达到 630 tokens/s。

开源项目与工程贡献

ApxInf 核心开发者

- 参与开源端侧推理引擎研发；项目采用 Rust 与 CUDA，面向 Jetson Thor/Orin 等设备上的具身模型推理。

KernelOwl / KerSor / AKW 主导设计与开发

- 开发 ReAct 运行时，统一 CLI、TUI 与 SDK，支持 MCP 扩展、任务图、Session/Trace 与上下文管理。
- 设计类型化任务交接和 Host 验证控制面，接入 Codex、Claude Code，支持失败回滚与最优版本管理。

GPU Infra / Agent GPU Broker 主导设计与开发

- 实现不可变候选提交、GPU 共享/独占调度及多卡原子分配，串联编译、正确性、Sanitizer 与测时。
- 在 A800/B200 上验证；通过 A800 的 SIGKILL 故障注入检查进程、容器及 GPU 资源回收并保留中断记录。

Cake IR / open-cake-ir 主导设计与开发

- 设计 Python DSL 与类型化 Schedule/Program IR，显式表达分块、存储和同步约束；实现 Triton、CUDA、CuTe DSL 与 Metal 代码生成路线。

EngineTailor 主导研发与论文第一作者

- 设计 Manager/Worker/Supervisor 协作与 worktree 隔离，分离生成和验收权限，贯通任务拆解、验证及归档。
- 在 Qwen3-4B/B200、并发 16 的同引擎场景优化图边界，输出吞吐从 3078.6 提升至 4654.8 tokens/s，提升 51.2%。

代表论文

EngineTailor DAI 2026 · 第一作者 · 已录用

Minimal Complete Inference Engines for Agent-Driven Optimization

ReasoningV ICAIS 2025 · 第一作者

Efficient Verilog Code Generation with Adaptive Hybrid Reasoning Model

技术能力

Agent 与系统：ReAct、MCP、任务图、Session/Trace、状态恢复、GPU 调度、独立评测、Docker、Linux

工程与推理：Python、C++/CUDA、PyTorch、Triton、SGLang、MLX/Metal、Git